

Extração de linhas georreferenciadas para Agricultura de Precisão

1st André Luiz da Silva Conde

Instituto Federal de São Paulo (IFSP)

Birigui, Brasil

andre.conde@aluno.ifsp.edu.br

2nd Higor Grigorio dos Santos

Instituto Federal de São Paulo (IFSP)

Birigui, Brasil

higor.santos@aluno.ifsp.edu.br

3rd Raul Prado Dantas

Instituto Federal de São Paulo (IFSP)

Birigui, Brasil

r.dantas@aluno.ifsp.edu.br

Abstract—Agriculture, an ancient and fundamental activity for human development, plays a crucial role in the Brazilian scenario, significantly contributing to the Gross Domestic Product (GDP) and exports of the country. With the rise of precision agriculture, driven by advanced technologies such as georeferencing and automation, there arises a need to overcome specific challenges, such as the automated georeferencing of agricultural images. Currently, this process is manually executed, demanding time and technical expertise. This work proposes an innovative approach by integrating image processing techniques and artificial intelligence to automate georeferencing, aiming to enhance efficiency, precision, and scalability. The methodology covers everything from image collection to the extraction of geographical coordinates from regions of interest, such as the trace of agricultural machinery, through segmentation using convolutional neural networks. The results, subject to rigorous validation, promise to substantially contribute to optimizing precision agriculture, representing a significant advancement in the application of artificial intelligence to the agricultural sector.

Index Terms—component, formatting, style, styling, insert

I. INTRODUÇÃO

A agricultura é uma atividade fundamental para a humanidade, sendo responsável pelo desenvolvimento de diversas civilizações e pela produção de alimentos. No Brasil, a agricultura tem evoluído significativamente, contribuindo com uma grande parcela do PIB e das exportações do país [6].

Com o avanço da tecnologia, a agricultura de precisão surgiu como uma forma de otimizar a produção e minimizar os custos e impactos ambientais. Essa abordagem utiliza tecnologias de georreferenciamento, como o GPS, e técnicas de automação, como drones e maquinário agrícola automatizado.

No entanto, um dos principais desafios enfrentados pela agricultura de precisão é a obtenção de dados de georreferenciamento de áreas de interesse em imagens de campos agrícolas. Atualmente, esse processo é realizado manualmente, o que consome tempo significativo e requer mão de obra especializada.

Este trabalho propõe uma solução para esse problema através da utilização de técnicas de processamento de imagens e inteligência artificial. A ideia é desenvolver uma solução automatizada para o georreferenciamento de imagens agrícolas, a fim de melhorar a eficiência, a precisão e a escalabilidade deste processo crucial.

Em resumo, este trabalho apresenta uma contribuição significativa para o avanço do conhecimento na área de IA aplicada à geografia, na área de processamento digital de imagens e para o desenvolvimento de novas ferramentas e aplicações que possam auxiliar os usuários em suas necessidades geográficas. Através da exploração e marcação geográfica automatizada, espera-se melhorar a eficiência e a precisão da agricultura de precisão.

II. AGRICULTURA

A agricultura, uma das atividades mais antigas da humanidade, desempenha um papel crucial no desenvolvimento de civilizações ao longo da história. No contexto brasileiro, a agricultura evoluiu significativamente, contribuindo substancialmente para o PIB e as exportações do país [6]. Atualmente, a agricultura representa 24,8% do PIB e 47,6% das exportações, com destaque para recordes na produção de soja e algodão. Diante desse cenário, a eficiência na condução da agricultura é vital para garantir sustentabilidade econômica e ambiental. A introdução de práticas inovadoras, como a agricultura de precisão, impulsiona a eficiência por meio do uso de tecnologias avançadas, incluindo o georreferenciamento.

A. Agricultura de Precisão

A agricultura de precisão, uma abordagem inovadora na gestão agrícola, utiliza tecnologias avançadas para otimizar a produção, reduzir custos e minimizar impactos ambientais. O georreferenciamento, com o auxílio de tecnologias como o GPS, desempenha um papel fundamental, permitindo um mapeamento preciso da área de produção. Essa técnica facilita um manejo mais eficiente dos recursos, como a aplicação precisa de fertilizantes e defensivos agrícolas, resultando na maximização da produtividade e na minimização do desperdício. A automação, por meio de drones e maquinário agrícola automatizado, também contribui para a eficiência do processo, destacando a importância do uso de tecnologias inovadoras.

B. Sistemas de Informação Geográfica (SIG)

Os Sistemas de Informação Geográfica (SIG) desempenham um papel crucial na agricultura de precisão, proporcionando a coleta, armazenamento, processamento e análise de dados geográficos. Esses sistemas, essenciais para a eficácia da

agricultura de precisão, geram informações geográficas, como mapas, e realizam análises espaciais. Destacam-se aplicações específicas, como a geração de mapas de produtividade, aplicação de insumos, colheita e linhas de maquinário. O processamento digital de imagens, integrado aos SIG, é essencial para transformar dados visuais em informações úteis, facilitando práticas eficientes de gestão agrícola.

III. PROCESSAMENTO DIGITAL DE IMAGENS

O Processamento Digital de Imagens é uma área de estudo que se concentra na manipulação e análise de imagens digitais para melhorar a qualidade ou extrair informações úteis, sendo um conjunto de técnicas computacionais voltadas para a análise de dados multidimensionais, como imagens que possuem conjuntos de valores numéricos representados em duas ou mais dimensões. Esses dados são adquiridos por sensores orbitais e suborbitais, normalmente embarcados em satélites, ônibus espacial, aviões, balões, drones, ou por dispositivos mais comuns, por exemplo câmeras de celulares.

[5], afirma que o PDI envolve a manipulação de uma imagem (ou dado) por computador, de tal maneira que a entrada e a saída do processo são imagens, tendo como objetivo principal melhorar o aspecto visual de certas feições estruturais, de tal maneira que o analista consiga melhor interpretar, classificar e tomar decisões com base nos dados existentes na imagem.

Suas técnicas podem ser aplicadas praticamente a toda e qualquer informação gerada via sensoriamento remoto. Seja a mesma obtida de maneira orbital, sub-orbital ou terrestre. Aplicações do PDI incluem áreas como: A análise de recursos naturais e meteorologia por meio de imagens de satélites; A transmissão digital de sinais de televisão ou *fac-símile*; A análise de imagens biomédicas; A análise de imagens metalográficas e de fibras vegetais; A obtenção de imagens médicas por ultra-som, radiação nuclear ou técnicas de tomografia computadorizada; Aplicações em automação industrial envolvendo o uso de sensores visuais em robôs.

A seguir as sessões serão apresentadas em ordem cronológica que o processamento digital de imagem ocorreu de acordo com o desenvolvimento do trabalho.

A. Pré Processamento

De acordo com [5], o pré-processamento de imagens digitais é uma etapa de fundamental importância para a obtenção de resultados satisfatórios em qualquer aplicação de processamento de imagens. O pré-processamento é uma etapa de preparação da imagem para as etapas seguintes, que podem ser de segmentação, classificação, reconhecimento, etc. O pré-processamento pode ser dividido em duas etapas: aquisição e melhoria da qualidade da imagem.

1) *Aquisição*: A aquisição de imagens é a primeira etapa do pré-processamento, e é responsável pela obtenção da imagem a ser processada, podendo ser feita por meio de digitalizadores, câmeras digitais, satélites, etc. A qualidade da imagem obtida depende diretamente do equipamento utilizado para a aquisição. Aquisição de imagens é uma etapa

fundamental, pois a qualidade da imagem obtida influencia diretamente na qualidade do resultado do processamento.

2) *Melhoria da qualidade*: A melhoria da qualidade da imagem é a segunda etapa do pré-processamento, e é responsável por realçar a qualidade da imagem obtida na etapa anterior. A melhoria da qualidade da imagem pode ser feita por meio de técnicas de filtragem, que podem ser de dois tipos: filtragem espacial e filtragem em frequência.

3) *Filtragem*: A filtragem é uma técnica de processamento de imagens que visa melhorar a qualidade da imagem por meio da remoção de ruídos e/ou realce de detalhes. A filtragem pode ser feita no domínio espacial ou no domínio da frequência. A filtragem espacial é feita por meio de máscaras de convolução, matrizes de números que são aplicadas sobre a imagem, enquanto, filtragem em frequência é feita por meio da transformada de Fourier, que transforma a imagem do domínio espacial para o domínio da frequência, onde a filtragem é feita, e depois a imagem é transformada novamente para o domínio espacial.

4) *Realce das Bordas*: O realce das bordas é uma técnica de processamento de imagens que visa realçar as bordas da imagem, de modo que as bordas fiquem mais visíveis. Este método é realizado por meio de máscaras de convolução, como a máscara de Sobel, Laplace e Roberts. O realce das bordas é uma técnica de filtragem espacial.

5) *Binarização*: A Binarização é uma técnica de processamento de imagens que visa transformar uma imagem em uma imagem binária, ou seja, uma imagem que possui apenas dois níveis de intensidade, preto e branco. A Binarização é feita por meio de um limiar, sendo um valor que determina se o *pixel* será preto ou branco. Se o valor do *pixel* for maior que o limiar, o *pixel* será branco, caso contrário, o *pixel* será preto.

6) *Redimensionamento*: O redimensionamento é uma técnica de processamento de imagens que visa alterar o tamanho da imagem. O redimensionamento pode ser feito por meio de interpolação, uma técnica que visa estimar o valor de um pixel a partir dos valores dos pixel vizinhos, sendo feita por meio de uma função de interpolação, que é uma função que mapeia o valor do pixel para um novo valor. O redimensionamento pode ser feito por meio de interpolações, como linear, bilinear ou bicúbica.

7) *Correções Geométricas*: A correção geométrica é uma etapa do pré-processamento que visa corrigir distorções geométricas presentes na imagem. A correção geométrica é feita por meio de pontos de controle, pontos de referência que possuem coordenadas conhecidas. A correção geométrica é feita por meio de transformações geométricas, transformações que alteram a posição dos *pixels* da imagem. As transformações geométricas mais utilizadas são: translação, rotação, escala, cisalhamento, etc.

8) *Normalização*: A normalização é uma técnica de processamento de imagens que visa alterar o intervalo de intensidade dos *pixels* da imagem. A normalização é feita por meio de uma função de normalização, uma função que mapeia o intervalo de intensidade original para um novo intervalo de intensidade.

B. Realce

O objetivo principal das técnicas de realce é processar uma imagem, de modo que a imagem resultante seja mais adequada para uma aplicação específica. [4] afirma a importância da ênfase na palavra *específica*, pois uma imagem pode ser melhorada para uma aplicação, mas para outra aplicação, a imagem pode não ser adequada. Por exemplo, uma imagem pode ser melhorada para uma aplicação de detecção de bordas, mas para uma aplicação de detecção de textura, a imagem pode não ser adequada.

As abordagens de realce podem ser divididas em duas categorias: realce no domínio espacial e realce no domínio da frequência. O domínio espacial refere-se ao próprio plano da imagem, logo as abordagens referentes a esse domínio são aplicadas diretamente sobre os pixels da imagem. Técnicas abordadas no domínio da frequência são aplicadas sobre a transformada de *Fourier* da imagem, sendo necessário realizar a transformada de *Fourier* da imagem, aplicar a técnica e depois realizar a transformada inversa de *Fourier*.

1) *Realce por Processamento Ponto a Ponto*: Técnicas de realce mais comuns são baseadas em processamento ponto-a-ponto (pixel a pixel), essa operação é caracterizada por uma função matemática aplicada a cada pixel da imagem, de modo que o valor do pixel resultante seja uma função do valor do pixel original, independente dos valores dos pixels vizinhos.

Um exemplo de realce ponto-a-ponto é a transformação de intensidade negativa. Negativos de imagens são úteis em aplicações de microscopia, onde a imagem é obtida por meio de um processo de revelação, e a imagem resultante é uma imagem negativa. O negativo de uma imagem é obtido por meio da negação do valor do pixel, ou seja, o valor do pixel resultante é igual ao valor máximo de intensidade menos o valor do pixel original. A ideia é reverter a imagem, de modo que os pixels mais escuros fiquem mais claros e os pixels mais claros fiquem mais escuros.

$$g(x, y) = L - 1 - f(x, y) \quad (1)$$

onde L é o valor máximo de intensidade e $f(x, y)$ é o valor do pixel original.

2) *Compressão da Escala Dinâmica*: A compressão de escala dinâmica é uma técnica de realce que visa melhorar o contraste da imagem, de modo que a imagem resultante possua um contraste melhor. A compressão de escala dinâmica é feita por meio de uma função que mapeia o intervalo de intensidade original para um novo intervalo de intensidade. De acordo com [4], uma alternativa eficiente para comprimir a escala dinâmica de uma imagem é a transformação logarítmica, dada por:

$$s = c \cdot \log(1 + |r|) \quad (2)$$

onde r é o valor do pixel original, s é o valor do pixel resultante e c é uma constante que controla a amplitude da transformação.

3) *Realce no Domínio da Frequência*: A ideia central do processamento no domínio da frequência é que certas operações, como filtragem, podem ser realizadas mais facilmente ou de forma mais intuitiva no domínio da frequência do que no domínio espacial. [4]

Inicialmente, a imagem é convertida do domínio espacial para o domínio da frequência usando a Transformada de Fourier, em imagens, normalmente é usada a Transformada de Fourier 2D.

No domínio da frequência, a imagem representada por suas frequências é multiplicada por um filtro. Essa multiplicação tem o efeito de "passar" ou "bloquear" certas frequências.

Por fim, a imagem modificada é convertida de volta ao domínio espacial usando a Transformada Inversa de Fourier, produzindo a imagem final realçada.

Para a realização das filtrações temos os seguintes filtros:

- **Passa-Baixa**: Ao usar um filtro passa-baixa, as bordas e outras transições abruptas, como o ruído, nos níveis de cinza de uma imagem, contribuem fortemente para o conteúdo de alta frequência da transformada de Fourier.
- **Passa-Alta**: Usando um filtro passa-alta, as bordas e contornos são mantidas, e em alguns casos realçando-as com alguns filtros, enquanto as componentes de baixa frequência são rejeitadas.
- **Homomórfica**: A filtragem homomórfica pode ser utilizada para comprimir o intervalo de iluminação e realizar o realce de contraste simultaneamente, resultando em uma imagem com evidentes melhorias de aparência.

C. Operações de Processamento

As operações de processamento de imagens desempenham um papel crucial na manipulação e melhoria da qualidade das imagens digitais. Estas operações envolvem uma série de técnicas e métodos que visam modificar características específicas da imagem para atender a requisitos específicos. Abaixo, destacam-se algumas das operações de processamento de imagens mais relevantes:

1) *Equalização de Histograma*: A equalização de histograma é uma técnica comumente utilizada para melhorar o contraste em imagens. Essa operação redistribui as intensidades dos pixels na imagem, de modo que a gama completa de intensidades seja mais bem aproveitada. Isso resulta em uma imagem com um espectro mais equilibrado de cores, o que pode ser benéfico para diversas aplicações, como reconhecimento de padrões e análise de texturas.

2) *Filtros de Suavização*: Os filtros de suavização são utilizados para reduzir o ruído e as imperfeições de uma imagem, tornando-a mais homogênea. Estes filtros incluem técnicas como a média, a mediana e a filtragem gaussiana. A aplicação de filtros de suavização é especialmente útil em imagens que possuem distorções devido a condições adversas, como iluminação inadequada ou interferência de sinal.

3) *Transformações Logarítmicas e Exponenciais*: As transformações logarítmicas e exponenciais são utilizadas para comprimir ou expandir a escala de intensidade de uma imagem. A transformação logarítmica é frequentemente utilizada

para realçar detalhes em áreas de baixa intensidade, enquanto a transformação exponencial pode ser empregada para realçar áreas de alta intensidade. Essas transformações são valiosas em situações onde certos detalhes necessitam de maior ênfase.

4) *Filtragem de Frequência*: A filtragem de frequência no domínio espacial visa realçar ou atenuar componentes de alta ou baixa frequência em uma imagem. Essa operação é frequentemente realizada por meio da aplicação de máscaras de convolução, que enfatizam ou suprimem determinadas características. A filtragem de frequência é útil em diversas aplicações, como a remoção de ruídos específicos ou o destaque de detalhes importantes.

5) *Transformação de Cores*: A transformação de cores refere-se à manipulação das componentes de cor em uma imagem. Pode incluir ajustes no equilíbrio de cores, saturação, intensidade, entre outros. Essas operações são valiosas para corrigir distorções de cor e garantir uma representação mais precisa da cena.

D. Segmentação de Imagens

A segmentação de imagens é uma tarefa de PDI que tem como objetivo a identificação de regiões de interesse em uma imagem, sendo capaz de separar a imagem em regiões, que podem ser utilizadas para a extração de características, para a classificação de imagens, entre outras tarefas.

A segmentação de imagens é uma tarefa de grande importância para o PDI, sendo utilizada em diversas áreas, como a medicina, a astronomia, a agricultura, entre outras. Na medicina é utilizada para a identificação de tumores, na astronomia é utilizada para a identificação de estrelas, na agricultura é utilizada para a identificação de plantas daninhas, entre outras aplicações.

Neste trabalho, a segmentação de imagens será utilizada para a identificação do traçado de maquinário agrícola, para a extração das coordenadas geográficas, para o uso em equipamentos de agricultura de precisão.

A segmentação de imagem será realizada através do uso de redes neurais convolucionais, que são redes neurais artificiais especializadas no processamento de imagens, sendo capazes de realizar a segmentação de imagens, a classificação de imagens, entre outras tarefas.

IV. INTELIGÊNCIA ARTIFICIAL

A Inteligência Artificial (IA) é uma subárea fascinante da ciência da computação, dedicada ao desenvolvimento de algoritmos e técnicas que habilitam os computadores a executar tarefas tradicionalmente associadas à inteligência humana. Isso inclui desafios como reconhecimento de padrões, aprendizado e tomada de decisão. [7]

As subáreas da IA, como aprendizado de máquina e processamento de linguagem natural, oferecem soluções especializadas para problemas distintos. Por exemplo, o aprendizado de máquina foca no treinamento de modelos para prever ou categorizar dados com base em exemplos anteriores, enquanto o processamento de linguagem natural lida com a interação entre máquinas e linguagem humana. [3]

Diversas técnicas são empregadas na implementação da IA, como redes neurais artificiais — inspiradas na estrutura do cérebro humano — e algoritmos genéticos que simulam a seleção natural.

A revolução trazida pela IA pode ser vista em diversas áreas. Na medicina, algoritmos são usados para prever doenças com base em registros médicos. Na astronomia, auxilia na categorização e descoberta de corpos celestes. Na agricultura, a precisão tem sido aprimorada com o uso de tecnologias baseadas em IA. [3]

Neste trabalho, focaremos na segmentação de imagens, uma tarefa crucial que permite a extração de coordenadas geográficas. Estas informações são fundamentais para a agricultura de precisão, possibilitando um gerenciamento mais eficiente dos cultivos e otimizando o uso de recursos.

A. Aprendizado de Máquina

O aprendizado de máquina (AM), uma das principais subáreas da inteligência artificial, se concentra na construção de sistemas capazes de aprender e aprimorar sua performance a partir da análise de dados. Estes sistemas são projetados para executar tarefas que, tradicionalmente, requerem a inteligência humana – como reconhecer padrões e tomar decisões baseadas em informações.

Segundo [3] podemos categorizar os algoritmos em algumas principais abordagens, dentre elas, podemos destacar:

- **Aprendizado Supervisionado**: Neste tipo, os algoritmos são treinados usando conjuntos de dados onde as respostas corretas são conhecidas. Ou seja, os dados são "rotulados". O objetivo é que o modelo possa fazer previsões ou inferências precisas quando apresentado a novos dados que se assemelham aos dados de treinamento.
- **Aprendizado Semi-Supervisionado**: Uma combinação de dados rotulados e não rotulados é utilizada para o treinamento. Isso é especialmente útil quando rotular dados é caro ou demorado. Os modelos aproveitam os dados não rotulados para melhorar sua generalização, atribuindo pesos ou confiabilidade diferenciados com base na sua confiança nas previsões.
- **Aprendizado Não Supervisionado**: Aqui, os algoritmos são expostos a dados que não possuem rótulos pré-definidos. O objetivo principal é descobrir estruturas ocultas nos dados, como grupos ou padrões. É como dar um quebra-cabeça ao algoritmo e pedir que ele identifique peças semelhantes.
- **Aprendizado por Reforço**: Embora não tenha sido mencionado anteriormente, vale a pena destacar que no aprendizado por reforço, o algoritmo aprende através de tentativa e erro, recebendo recompensas ou punições com base nas ações que realiza.

B. Redes Neurais Artificiais

As Redes Neurais Artificiais (RNA) são modelos computacionais inspirados na estrutura do sistema nervoso central de seres vivos. O núcleo dessas redes são os neurônios artificiais,

unidades de processamento que recebem valores de entrada, processam-nos e geram um valor de saída.

A interconexão entre esses neurônios se dá por meio de 'sinapses artificiais', que têm pesos associados. Esses pesos determinam a importância e influência de um neurônio sobre o outro.

O conceito de redes neurais não é recente. A ideia remonta à década de 1940 com pioneiros como Warren McCulloch e Walter Pitts, que introduziram redes simples baseadas em neurônios binários, que simulavam o funcionamento dos neurônios biológicos, contudo este modelo era muito limitado sendo capaz de resolver apenas problemas linearmente separáveis, e ao introduzir múltiplas camadas ocorria-se o problema de desvanecimento de gradiente resultando em pequenas alterações em redes muito profundas. [1]

Felizmente, técnicas avançadas de treinamento foram desenvolvidas para combater esse problema. Algoritmos como o Resilient Propagation, que otimiza sem depender estritamente da derivada do erro, e o Adam, que ajusta dinamicamente as taxas de aprendizado, são soluções inovadoras que permitem que as redes neurais de multiplas camadas aprendam de forma eficaz e eficiente. [1]

Segundo [3] as RNA's podem ser classificadas em categorias, baseado na forma como os dados são passados entre as camadas, e na forma como os neurônios estão conectados. Com base nisso temos as seguintes categorias:

- **Feedforward:** Neste tipo de rede, os neurônios de uma camada estão conectados apenas aos neurônios da camada seguinte.
- **Feedback:** Em redes *Feedback*, os neurônios além de estarem conectados aos da camada seguinte, estão conectados ao valor obtido na saída, de forma a seu valor atual, depender do resultado de saída passado.

E para as conexões entre neurônios as seguintes classificações:

- **Completamente conectada:** Quando os neurônios da camada estão conectados a todos os neurônios da camada seguinte e/ou anterior.
- **Localmente conectada:** Quando os neurônios que estão conectados a camada seguinte e/ou anterior estão em uma região bem definida.
- **Parcialmente conectada:** Quando os neurônios estão conectados a apenas alguns dos neurônios da camada anterior e/ou seguinte.

As RNAs multicamadas, também conhecidas como redes profundas, têm a capacidade de executar tarefas muito mais complexas, como classificar e segmentar imagens. No entanto, elas enfrentam desafios, como o desvanecimento do gradiente. Esse fenômeno ocorre durante o treinamento, quando os ajustes necessários nos pesos (através do método de gradiente descendente) tornam-se muito pequenos, impedindo a rede de aprender adequadamente.

Em uma RNA, os neurônios estão organizados em camadas:

- **Camada de Entrada:** Recebe dados externos e os transfere para a camada seguinte.

- **Camadas Ocultas:** Localizadas entre a entrada e a saída, processam os dados transferindo-os adiante.
- **Camada de Saída:** Produz o resultado final da rede.

C. Redes Neurais Convolucionais

As Redes Neurais Convolucionais (CNNs), derivadas do inglês *Convolutional Neural Network*, têm emergido como um paradigma crucial no campo da aprendizagem profunda, especialmente em aplicações que envolvem processamento de imagens.

Inspirando-se na organização do córtex visual humano, as CNNs possuem uma estrutura única e diferenciada. Esta estrutura é composta principalmente por:

- **Camada Convolucional:** Esta camada implementa uma operação de convolução, que envolve a aplicação de filtros para detectar padrões locais, como bordas e texturas. É pertinente observar que cada filtro é treinado para identificar um tipo específico de característica na entrada.
- **Camada de Pooling:** Sequencialmente à operação de convolução, as CNNs empregam uma camada de pooling. Esta camada visa reduzir a dimensionalidade espacial, retraindo as características mais salientes. Um exemplo comum dessa operação é o "Max Pooling", que seleciona o valor máximo em uma janela definida.
- **Camada Totalmente Conectada:** Em suas camadas finais, as CNNs convergem para uma estrutura densamente conectada, semelhante às redes neurais tradicionais. Aqui, as características reconhecidas são utilizadas para realizar funções como classificação ou regressão.

As Redes Neurais Convolucionais têm estabelecido novos padrões no domínio da visão computacional e do processamento de imagens. Através da compreensão de sua arquitetura e das nuances que as distinguem de outros modelos, é possível otimizar sua implementação para diversas aplicações, promovendo avanços significativos no campo da inteligência artificial.

V. METODOLOGIA

Neste capítulo, será apresentada a metodologia utilizada para desenvolver a solução proposta. O processo de georreferenciamento automatizado de imagens agrícolas envolverá diversas etapas, desde a aquisição das imagens até a extração e aplicação das coordenadas geográficas.

Inicialmente, as imagens adquiridas passaram por um processo de recorte, para que seja possível a segmentação da imagem. Após o recorte, as imagens foram segmentadas por meio de redes neurais convolucionais, o principal objetivo da segmentação é o destaque do traçado das ruas agrícolas, para que seja possível a extração das coordenadas geográficas através de algoritmos de processamento de imagens.

A. Aquisição de Dados

A obtenção de imagens agrícolas é o ponto de partida do processo. Essas imagens podem ser adquiridas por meio de drones equipados com câmeras de alta resolução, satélites ou outras fontes de sensoriamento remoto. A escolha da fonte

de dados dependerá das necessidades específicas do projeto, considerando fatores como resolução espacial, cobertura da área e frequência de aquisição.

B. Pré-processamento das Imagens

As imagens adquiridas passarão por um processo de pré-processamento para garantir a qualidade e uniformidade necessárias para as etapas subsequentes. Isso inclui correções geométricas, remoção de ruídos, ajustes de contraste e brilho, entre outros. O objetivo é preparar as imagens de maneira adequada para a segmentação e extração de coordenadas geográficas.

C. Segmentação de Imagens com Redes Neurais Convolucionais

A segmentação de imagens será realizada por meio de redes neurais convolucionais (CNNs). Essas redes são capazes de aprender padrões complexos em imagens e são particularmente eficazes em tarefas de segmentação. O treinamento da CNN envolverá o uso de conjuntos de dados rotulados, onde as regiões de interesse nas imagens estarão marcadas.

D. Extração de Coordenadas Geográficas

Uma imagem saída do processo de segmentação de imagens não possui nenhuma informação geográfica, sendo necessário a extração das coordenadas geográficas das regiões de interesse, para que se possa utilizar as informações extraídas para o uso em equipamentos de agricultura de precisão.

Dessa forma é necessário o desenvolvimento de um algoritmo que seja capaz de extrair as coordenadas geográficas das regiões de interesse, e aplicá-las a imagem resultante do processo de segmentação.

E. Validação da Solução

A solução proposta será validada por meio da comparação das coordenadas geográficas extraídas automaticamente com coordenadas de referência conhecidas. A precisão e eficácia do método serão avaliadas em diferentes cenários e condições.

VI. RESULTADOS E DISCUSSÃO

Neste capítulo, serão apresentados os resultados obtidos com a implementação da solução proposta. Serão discutidos os desempenhos da segmentação de imagens, da extração de coordenadas geográficas e da validação da solução em diferentes contextos agrícolas. Serão também abordadas possíveis limitações e melhorias para trabalhos futuros.

O recorte da área de interesse é segmentado por meio de redes neurais convolucionais, treinadas para destacar as regiões de interesse com base em imagens rotuladas. A Figura 01 apresenta a imagem de entrada, e sua saída após a segmentação com rede neural convolucional na Figura 02.

A partir das imagens processadas pelas redes neurais convolucionais, foi possível aplicar algoritmos de processamento de imagens para a extração das coordenadas geográficas das regiões de interesse. Com a finalidade de ajustar e melhorar o resultado dos algoritmos de esquelitização, aplicamos um algoritmo de dilatação. A dilatação remove áreas que podem

Fig. 1. Figura 01 - Imagem de entrada


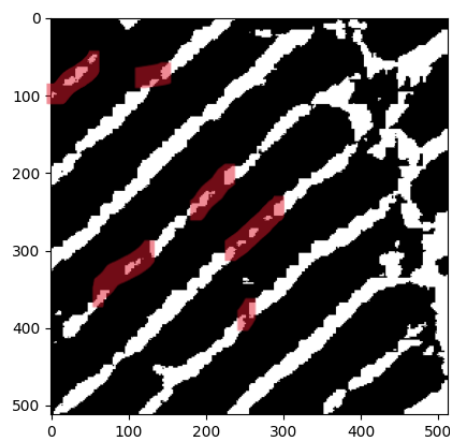


Fig. 2. Figura 02 - Imagem segmentada



atrapalhar o resultado dos algoritmos de esquelitização, como as destacadas em vermelho na imagem 02. Após a dilatação, obtemos a imagem 03, nela é possível aplicar o algoritmo de extração de bordas, uma vez que parte das imperfeições foram removidas. O algoritmo aplicado para extração das bordas foi canny. A imagem 04 apresenta o resultado da extração.

Por fim, aplicando esquelitização, obtemos a imagem 05. Essa imagem é uma ilustração dos esqueletos obtidos sobre a imagem de entrada, que são utilizados para a extração das coordenadas geográficas. É relevante mencionar que nessa etapa, obtemos um vetor de pixels que representam o esqueleto, e a partir desse vetor, é possível realizar a conversão para coordenadas geográficas, através de escalas e coordenadas de referência.

Embora os resultados tenham sido satisfatórios, existem fatores que podem afetar a precisão da solução. A qualidade

Fig. 3. Imagem após a dilatação




Fig. 4. Imagem após extração das bordas

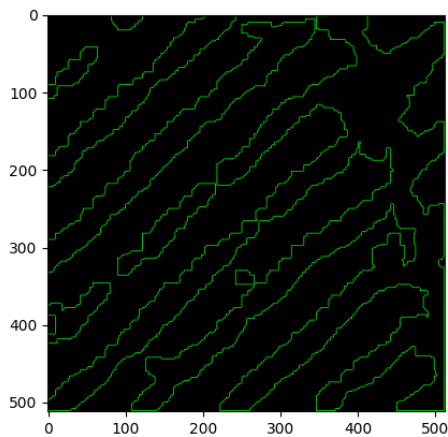
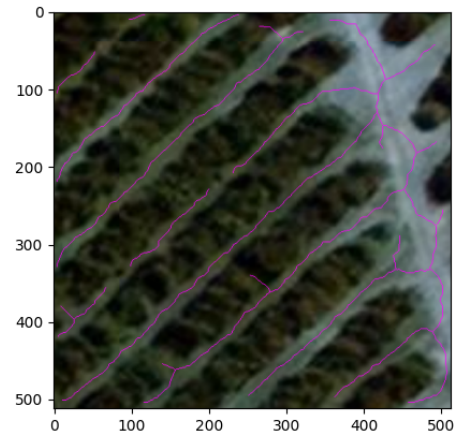


Fig. 5. Imagem após extração do esqueleto



as coordenadas geográficas de maquinário agrícola, para o uso em equipamentos de agricultura de precisão.

REFERENCES

- [1] BRAGA, A. P.; CARVALHO, A. P. L. F.; LUDERMIR, T. B. Redes Neurais Artificiais: Teoria e Aplicações. 2. ed. [S.l.]: LTC, 2016.
- [2] BRAGA, D. F. M. M. d. S. Algoritmos de processamento da linguagem natural para sistemas de conversao texto-fala em português. 2008.
- [3] FACELI, K. et al. Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina. 2. ed. [S.l.]: LTC, 2022.
- [4] GONZALEZ, R. C.; WOODS, R. E. Processamento Digital de Imagens. 1. ed. [S.l.]: Edgard Blücher Ltda, 2000. ISBN 8576054019.
- [5] GONZALEZ, R. C.; WOODS, R. E. Processamento Digital de Imagens. [S.l.]: Pearson Universidades, 2009. ISBN 8576054019.
- [6] LAMAS, F. M. A evolução da agricultura do brasil. EMBRAPA, 2023. Disponível em: <https://www.embrapa.br/busca-de-noticias/-/noticia/81665485/artigo-a-evolucao-da-agricultura-do-brasil>.
- [7] LIMA, I.; PINHEIRO, C. A. M.; SANTOS, F. A. O. Inteligência Artificial. 1. ed. [S.l.]: Elsevier, 2014.

das imagens de entrada, por exemplo, pode influenciar o desempenho da segmentação e extração de coordenadas geográficas. Além disso, a solução proposta pode ser aprimorada com o uso de técnicas avançadas de processamento de imagens e aprendizado de máquina.

VII. CONCLUSÃO

Neste trabalho, foi proposta uma solução para o georreferenciamento automatizado de imagens agrícolas. A solução envolveu o uso de redes neurais convolucionais para a segmentação de imagens e a extração de coordenadas geográficas. A solução foi validada em diferentes cenários e condições, o algoritmo é capaz não só de extrair linhas retas, mas também curvas, o que é muito comum em maquinário agrícola. Embora os resultados tenham sido satisfatórios, existem fatores que Portanto a solução proposta é capaz de extrair